

Relatorio de Correcoes e Adequacoes — Pipeline CAGED

Data: 2026-03-05 **Arquivo principal modificado:** `pipeline/extract/caged_rais.py` **Escopo:** Coleta, normalizacao e processamento dos microdados CAGED (Antigo 2015-2019 + Novo 2020-2025) para os 9 estados do Nordeste.

1. Bug Critico: salario_medio == total_movimentacoes

Sintoma: O campo `salario_medio` continha exatamente o mesmo valor de `total_movimentacoes` em 100% dos registros do CAGED Antigo, indicando que o calculo da media salarial estava incorreto.

Causa raiz: Mojibake nos nomes de colunas. Os arquivos do FTP usam encoding `latin-1`, mas o nome da coluna `Salario Mensal` continha acentos que, ao serem lidos, geravam caracteres corrompidos (ex: `SalÃirio Mensal`). O mapeamento de colunas usava correspondencia exata e nao encontrava a coluna de salario. Como resultado, o `pd.DataFrame.agg()` com ternario condicional caia no fallback `("saldo_movimentacao", "count")`, que retornava a contagem de movimentacoes no lugar da media salarial.

Correcao aplicada:

- Adicionada funcao `_fix_mojibake()` que reverte a corrupcao de encoding (`latin-1` → `UTF-8`)
- Aplicada antes do mapeamento de colunas em `_normalize_columns()`
- Mapeamento de salario alterado para usar correspondencia por substring (`"salario" in lc`) alem de correspondencia exata

2. Crash no CAGED Novo: Mapeamento Duplicado de Colunas

Sintoma: `TypeError: arg must be a list, tuple, 1-d array, or Series` ao processar CAGED Novo (a partir de jan/2020).

Causa raiz: Tres colunas diferentes do CAGED Novo continham "salario" no nome:

- `salario` (campo generico)
- `unidadesalarioCodigo` (codigo da unidade de salario — NAO e um valor monetario)
- `valorsalariofixo` (valor do salario fixo — campo correto)

O mapeamento por substring (`"salario" in lc`) fazia as tres colunas serem renomeadas para "salario", criando colunas duplicadas. Ao chamar `df["salario"]`, o pandas retornava um DataFrame (nao Series), causando o `TypeError`.

O mesmo problema ocorria com `competencia`: `competenciamov` e `competenciadec` ambas mapeavam para "competencia".

Correcao aplicada:

- Pre-deteccao de colunas prioritarias antes do loop de mapeamento

- `valorsaláriofixo` tem prioridade sobre `salário` generico
- `competênciamov` tem prioridade sobre `competênciadec`
- Se a coluna prioritaria existe, a generica e ignorada (nao mapeada)

3. Salario Medio NaN no CAGED Novo (Virgula Decimal)

Sintoma: Apos corrigir o mapeamento, apenas 18 de 648 registros do CAGED Novo tinham `salario_medio` preenchido. Os demais eram NaN.

Causa raiz: Os microdados do CAGED usam virgula como separador decimal (padrao brasileiro, ex: `1500,00`). A funcao `pd.to_numeric("1500,00")` retorna NaN porque espera ponto decimal. O CAGED Antigo ja tratava isso (linha 243), mas o CAGED Novo nao.

Correcao aplicada:

- Adicionada conversao `str.replace(",", ".", regex=False)` antes de `pd.to_numeric()` na funcao `_processar_caged_mes()` (CAGED Novo)

4. Harmonizacao do Campo sexo (eSocial vs CAGED Antigo)

Sintoma: No CAGED Novo (pos-eSocial), o codigo `sexo=3` representava feminino (6.16M admissoes), enquanto no CAGED Antigo `sexo=2` = feminino.

Causa raiz: O eSocial utiliza codificacao diferente do CAGED Antigo para o campo sexo: `1=Masculino, 3=Feminino` vs `1=Masculino, 2=Feminino`.

Correcao aplicada:

- Adicionado `df["sexo"] = df["sexo"].replace({3: 2})` na funcao `_processar_caged_mes()` para padronizar feminino como `2` em ambas as bases.

5. Normalizacao do Campo grau_instrucao

Sintoma: Inconsistencia entre anos no campo `grau_instrucao` — alguns registros tinham zero-padding (ex: `"01"` vs `1`), causando categorias duplicadas na agregacao.

Correcao aplicada:

- Conversao para numerico com `pd.to_numeric()` tanto no CAGED Antigo quanto no Novo, garantindo tipo inteiro uniforme.

6. Arquivos Corrompidos no FTP (Sem Correcao Possivel)

Situacao: 13 arquivos `.7z` no servidor FTP do MTE estao corrompidos e nao podem ser extraidos. Isso afeta os seguintes meses do CAGED Antigo:

Ano	Meses Corrompidos
-----	-------------------

Ano	Meses Corrompidos
2015	Jan, Mar, Jul, Nov
2016	Mar, Mai
2017	Mar, Abr, Mai, Jun, Ago, Set, Out

Impacto: 13 meses sem dados do CAGED Antigo para todos os estados. Na agregacao bimestral, os bimestres afetados tem dados parciais (apenas 1 mes ao inves de 2), subestimando movimentacoes em ~50%.

Mitigacao possivel (futura): Interpolacao temporal usando medias moveis ou modelos de sazonalidade com base nos meses adjacentes disponiveis.

7. Dados do CAGED Novo — Escolha da Coluna de Salario

O CAGED Novo (eSocial) possui duas colunas de salario:

- salário: salario contratual total (media NE: ~R\$ 2.022)
- valorsaláriofixo: valor do salario fixo, excluindo parcelas variaveis (media NE: ~R\$ 1.563)

Decisao: Utilizamos **valorsaláriofixo** por ser o campo mais comparavel com o **Salario Mensal** do CAGED Antigo, que tambem registrava o salario fixo contratual.

Resumo dos Resultados Apos Correcoes

Metrica	Antes	Depois
salario_medio = total_mov (bug)	100%	0%
Registros com salario (Antigo)	0/423	423/423
Registros com salario (Novo)	18/648	648/648
Mediana salario Antigo	N/A	R\$ 1.207
Mediana salario Novo	N/A	R\$ 1.501
Crash CAGED Novo	Sim	Nao
sexo padronizado	Nao	Sim
grau_instrucao padronizado	Nao	Sim

Arquivos Gerados/Atualizados

Dados brutos (**dados_nordeste/raw/caged/nordeste/**)

- caged_antigo_saldo_mensal.csv** — 423 registros (2015-2019)
- caged_antigo_por_perfil.csv** — 810 registros
- caged_saldo_mensal.csv** — 648 registros (2020-2025)

- [caged_por_setor.csv](#) — 1.107 registros
- [caged_por_perfil.csv](#) — 1.317 registros

Dados processados ([dados_nordeste/processed/](#))

- [caged/nordeste/caged_bimestral.csv](#) — 594 registros (2015-2025, bimestral)
- [caged/<uf>/caged_saldo_mensal.csv](#) — por estado
- [caged/<uf>/caged_antigo_saldo_mensal.csv](#) — por estado

Planilha consolidada

- [dados_nordeste/caged_consolidado.xlsx](#) — 6 abas, agora com coluna Salario Medio (R\$)

Nota sobre Outliers de Salario

Alguns registros apresentam salario medio extremamente alto (ex: PI out/2021 com R\$ 1.9M). Isso ocorre porque a media e sensivel a registros com salarios atipicos (diretores, cargos executivos). Para o modelo econometrico, recomenda-se:

1. Usar **mediana** ao inves de media, ou
2. Aplicar **winsorization** (truncar nos percentis 1% e 99%), ou
3. Filtrar salarios acima de um teto (ex: R\$ 50.000)